RÉFÉRENCE TECHNIQUE · DÉTECTION D'ANOMALIES POUR LE SOC



Statistiques & apprentissage automatique

pour la détection d'anomalies

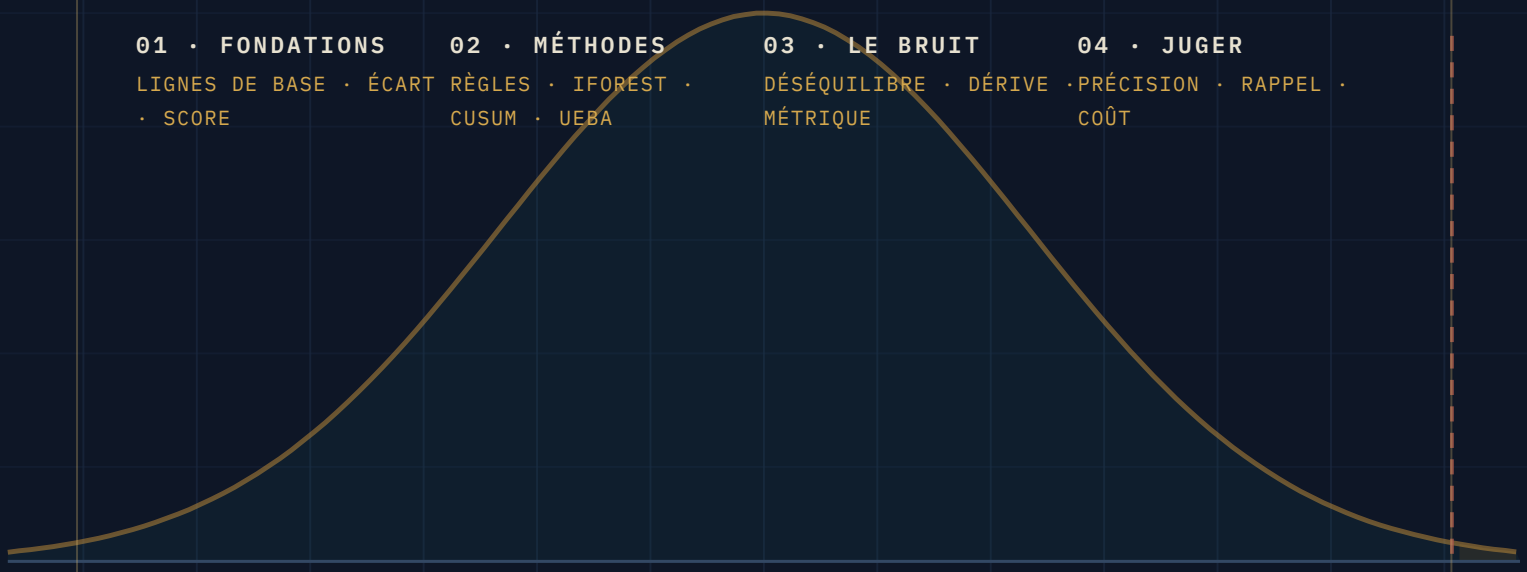
Des lignes de base aux scores d'anomalie, des règles statistiques à l'UEBA : comprendre ce que mesurent vraiment les outils, et pourquoi la plupart font du bruit.

01 · FONDATIONS
LIGNES DE BASE · ÉCART · SCORE

02 · MÉTHODES
RÈGLES · IFOREST · CUSUM · UEBA

03 · LE BRUIT
DÉSÉQUILIBRE · DÉRIVE · MÉTRIQUE

04 · JUGER
PRÉCISION · RAPPEL · COÛT



0x

0xKuraishY

AUTEUR · GUIDE DE TERRAIN

ÉDITION 2026
LECTURE ≈ 45 MIN
V1.0

À PROPOS DE CE GUIDE

Lire ce guide

Ce document s'adresse à l'**analyste SOC confirmé** : quelqu'un qui lit des journaux, écrit des règles de corrélation et vit avec des files d'alertes, mais qui n'est pas data scientist de métier. L'objectif n'est pas de former un statisticien, mais de donner le vocabulaire et les réflexes pour **juger** une détection pilotée par les données et dialoguer d'égal à égal avec ceux qui la construisent.

On y explique sans jargon inutile : lignes de base et saisonnalité, façons de mesurer un écart, scores d'anomalie, puis les grandes familles de méthodes. Une partie entière est consacrée à une question impopulaire : **pourquoi la plupart des outils « IA » produisent surtout du bruit** — et comment le reconnaître.

Le parti pris est la **franchise sur les limites**. Chaque méthode a un domaine où elle brille et un domaine où elle échoue ; aucune n'est magique. Les chiffres des exemples sont volontairement simples pour rester vérifiables ; les affirmations importantes renvoient à des **sources sérieuses**, rassemblées en fin d'ouvrage.

Chaque chapitre suit la même partition : une *idée clé*, une *intuition*, un *exemple chiffré*, un *piège fréquent*, puis un *à retenir*. Les cinq repères :

IDÉE CLÉ
Le principe du chapitre en une ou deux phrases — ce qu'il faut avoir compris avant tout.

INTUITION
Une image mentale, une analogie : pourquoi la méthode marche, sans les mathématiques.

EXEMPLE CHIFFRÉ
Un petit calcul concret, avec de vrais nombres, reproductible de tête ou sur un coin de table.

PIÈGE FRÉQUENT
L'erreur classique qui transforme une bonne idée en générateur d'alertes inutiles.

À RETENIR
Le condensé de fin de chapitre : ce que vous emportez si vous ne reteniez qu'un encadré.

Les renvois numérotés entre crochets, comme `[1]`, pointent vers la bibliographie « Sources & références ». Le sommaire est cliquable et des signets accompagnent la navigation.

TABLE DES MATIÈRES

Sommaire

Introduction — Le problème du bruit

PARTIE I Fondations statistiques

1 Lignes de base et saisonnalité ..... SÉRIES TEMPORELLES
2 Mesurer un écart : σ, z-score robuste, quantiles ..... DISPERSION
3 Du signal au score d'anomalie ..... SCORES & SEUILS

PARTIE II Les grandes familles de méthodes

4 Règles statistiques (3σ, EWMA, percentiles) ..... BASELINE
5 Isolation Forest et l'approche non supervisée ..... FORÊTS
6 Détection de changement (CUSUM, ruptures) ..... TEMPS RÉEL
7 UEBA : le comportement comme ligne de base ..... ENTITÉS

PARTIE III Pourquoi l'« IA » fait du bruit

8 Le déséquilibre des classes et le taux de base ..... BASE RATE
9 La dérive : quand le normal bouge ..... DRIFT
10 La mauvaise métrique (exactitude, ROC) ..... ÉVALUATION
11 L'absence de contexte ..... ENRICHISSEMENT

PARTIE IV Juger une détection

12 Précision, rappel et coût des faux positifs ..... MESURES
13 La grille d'évaluation ..... DÉCISION

Conclusion

Sources & références

00

INTRODUCTION

Le problème du bruit

Un SOC ne meurt pas d'un manque d'alertes. Il meurt sous leur nombre. Chaque éditeur promet désormais une détection « pilotée par l'IA » capable de repérer l'inconnu ; et chaque analyste a, un jour, fermé un tableau de bord qui clignotait rouge sans qu'aucune de ses centaines d'alertes ne mérite qu'on se lève la nuit.

Ce guide part d'un constat simple : derrière le mot « anomalie » se cache de la statistique, parfois élégante, souvent mal réglée. Comprendre cette statistique ne demande pas de devenir data scientist. Il suffit de saisir quelques idées — ce qu'est une **ligne de base**, comment on **mesure un écart**, ce qu'est un **score d'anomalie** — puis de reconnaître les mécanismes qui, presque toujours, font déraper ces outils vers le bruit.

La thèse centrale de cet ouvrage tient en une phrase, et elle est connue depuis l'an 2000 : dans la détection d'intrusion, **le facteur limitant n'est pas la capacité à détecter, mais le taux de fausses alarmes** [1]. Un détecteur « à 99 % » peut rester inutilisable si les événements vraiment malveillants sont rares — et ils le sont. Tout le reste découle de là.

Le parcours est en quatre temps. La **Partie I** pose les fondations : lignes de base, mesure de l'écart, scores. La **Partie II** présente les grandes familles de méthodes — règles statistiques, Isolation Forest, détection de changement, UEBA. La **Partie III** explique sans détour pourquoi l'« IA » fait du bruit : déséquilibre des classes, dérive, mauvaise métrique, absence de contexte. La **Partie IV** propose une méthode pour juger si une détection vaut vraiment quelque chose.

> ⓘ NOTE D'HONNÊTETÉ
> Aucune méthode de ce guide n'est magique, et aucune n'est disqualifiée. Chacune a un terrain où elle excelle et un terrain où elle échoue ; l'essentiel est de savoir lequel. Quand une limite est importante, elle est dite — c'est le seul moyen de garder une relation saine avec ses outils.

PARTIE I

Fondations statistiques

Définir le normal, mesurer l'écart, transformer un signal en score. Tout le reste s'appuie sur ces trois gestes.

1 Lignes de base et saisonnalité

2 Mesurer un écart : σ, z robuste, quantiles

3 Du signal au score d'anomalie

01

PARTIE I · FONDATIONS

Lignes de base et saisonnalité

Avant de parler d'anomalie, il faut définir le normal. Et le normal, dans un système vivant, n'est jamais un nombre unique : c'est une valeur attendue qui respire au rythme des heures, des jours et des semaines.

> **IDÉE CLÉ**
> Une **ligne de base** (*baseline*) est la valeur *attendue* d'une métrique à un instant donné, compte tenu de son histoire. Une anomalie n'est pas un écart à la moyenne globale, mais un écart à cette valeur attendue — qui varie dans le temps.

1.1 Tendance, saisonnalité, résidu

On décompose utilement une série temporelle en trois morceaux : une **tendance** (la dérive lente de fond), une **saisonnalité** (les motifs qui se répètent — cycle journalier, hebdomadaire) et un **résidu** (ce qui reste une fois les deux premiers retirés). C'est dans le résidu que vivent les anomalies : une fois la respiration normale soustraite, ce qui dépasse mérite attention.

Le volume d'authentifications d'une entreprise illustre tout : creux la nuit, pic le matin, effondrement le week-end. Comparer la valeur de 3 h du matin à la *moyenne de la journée* n'a aucun sens ; il faut la comparer au *3 h du matin habituel*.

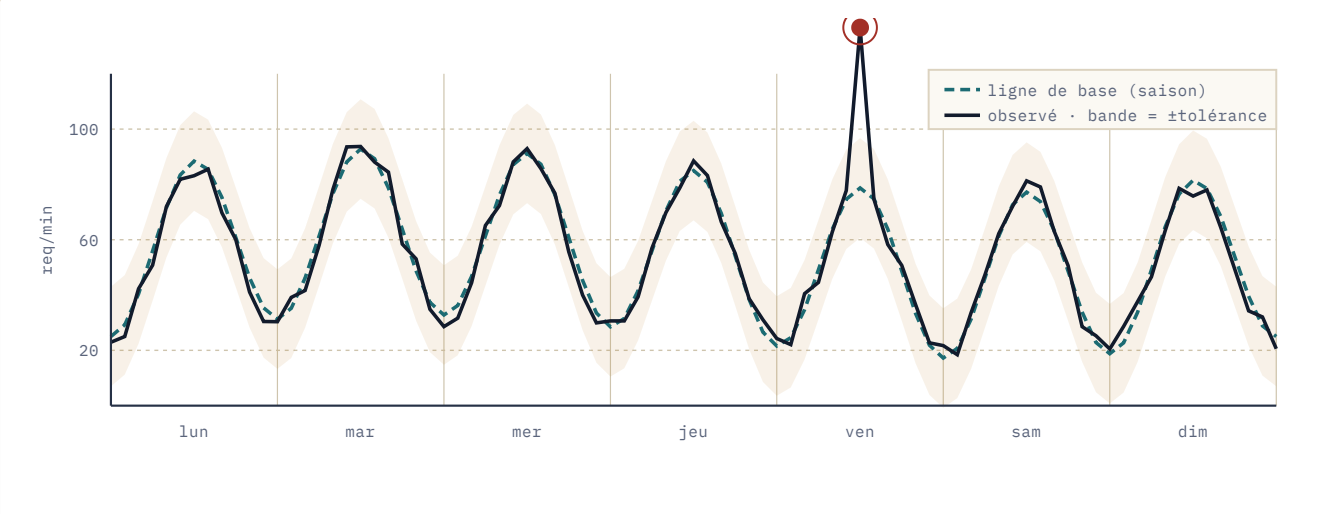


FIG. 1 Une semaine d'activité. La courbe pointillée est la ligne de base saisonnière ; la bande, sa tolérance. Le pic du vendredi sort de la bande : *c'est l'écart au motif attendu, pas la hauteur absolue, qui le rend anormal.*

1.2 Un chiffre qui parle

EXEMPLE CHIFFRÉ

Moyenne globale (toute la semaine)	**≈ 50 req/min**
Ligne de base — mardi 10 h	**≈ 90 req/min**
Ligne de base — dimanche 3 h	**≈ 12 req/min**
Valeur observée mardi 10 h	**70 req/min**
vs moyenne globale (+20)	**« au-dessus », banal**
vs base attendue (−20)	**anormalement BAS ⚠**

La même valeur de 70 est *au-dessus* de la moyenne globale mais nettement *en dessous* de l'attendu pour un mardi matin — possible panne, blocage ou exfiltration qui détourne le trafic. Sans saisonnalité, on l'aurait manquée.

⚠ PIÈGE FRÉQUENT

Comparer à une moyenne plate ignore la saisonnalité et déclenche une alerte à *chaque* pic légitime du matin ; on apprend alors à ignorer l'outil. Autre piège, plus sournois : apprendre la ligne de base sur une fenêtre qui **contient déjà un incident**. Le modèle absorbe l'attaque comme « normale » et deviendra aveugle à sa répétition.

À RETENIR

— Le « normal » est une courbe, pas une constante : pensez **tendance** + **saisonnalité** + **résidu**.

— Comparez toujours une valeur à **son** moment attendu (même heure, même jour), pas à une moyenne globale.

— Une baseline s'apprend sur une période **propre** ; une fenêtre polluée par un incident empoisonne la détection.

02

PARTIE I · FONDATIONS

Mesurer un écart : σ, z-score robuste, quantiles

Une fois le normal défini, il faut une règle graduée : « à quelle distance ? ». Trois outils, par ordre de robustesse croissante — l'écart-type, sa version robuste, et les quantiles qui ne supposent rien.

> **IDÉE CLÉ**
> Mesurer un écart, c'est le rapporter à une **échelle de dispersion**. L'écart-type donne le fameux `z-score`, simple mais fragile ; la médiane et le `MAD` en donnent une version **robuste** ; les **quantiles** se passent de toute hypothèse sur la forme des données.

2.1 Le z-score et la règle des 3σ

Le z-score mesure la distance à la moyenne en nombre d'écarts-types : `z = (x − μ) / σ`. Sous une loi normale, environ 99,7 % des valeurs tiennent dans μ ± 3σ ; franchir +3σ ne concerne qu'environ **0,13 %** des observations d'un côté. D'où le réflexe « au-delà de 3σ, on alerte ».

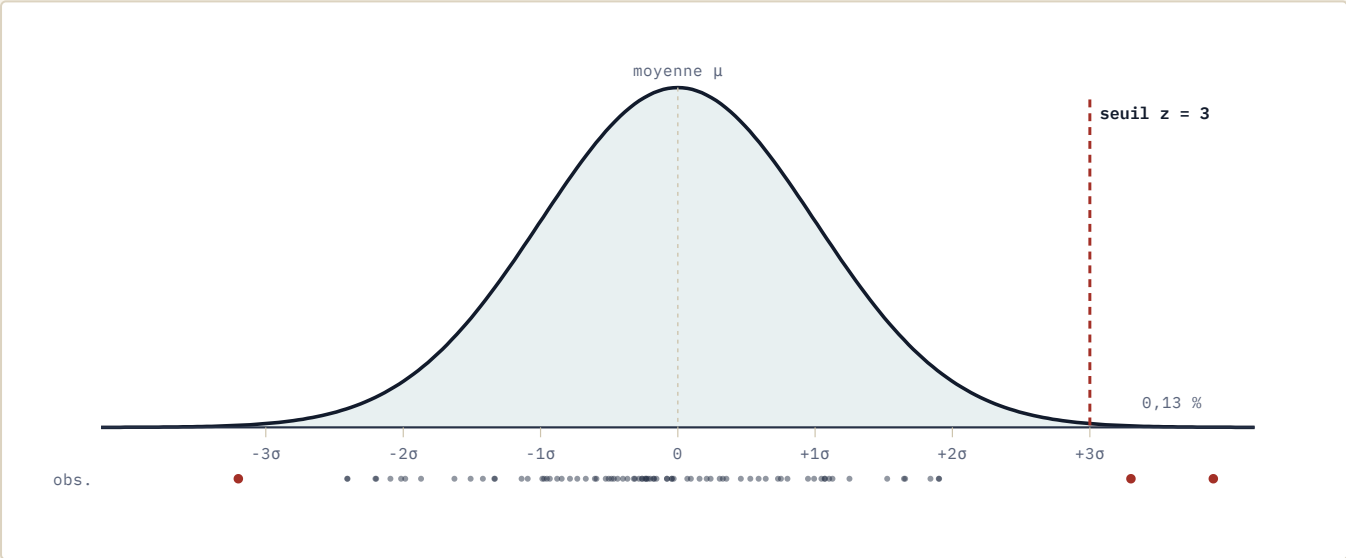


FIG. 2 La courbe normale et le seuil à z = 3. La queue ombrée (≈ 0,13 %) est la zone d'alerte. Les points rouges, au pied du graphe, sont les observations qui franchissent le seuil.

2.2 Pourquoi σ se fait piéger : le masquage

La moyenne et l'écart-type sont eux-mêmes **sensibles aux valeurs extrêmes**. Une seule valeur énorme gonfle σ au point de rendre invisibles des anomalies plus discrètes : c'est le **masquage**. Leys et al. recommandent donc de ne pas utiliser l'écart-type autour de la moyenne, mais l'**écart absolu autour de la médiane** (MAD) [2].

EXEMPLE CHIFFRÉ

Grappe normale	≈ 50
+ anomalie discrète	70
+ valeur extrême	940
Classique : μ = 115.5, σ = 228.8	μ+3σ ≈ 802
→ z(70) = −0,2	NON signalé ✗ (masqué)
Robuste : médiane = 51.5, 1,4826·MAD = 5.19	seuil ≈ 67
→ z-robuste(70) ≈ 3,6	signalé ✓

L'extrême (940) dilate σ jusqu'à 229 ; la bande μ ± 3σ s'étale jusqu'à 802 et **avale l'anomalie à 70**. La médiane et le MAD, eux, n'ont pas bougé : la bande robuste reste serrée et signale les *deux* anomalies.

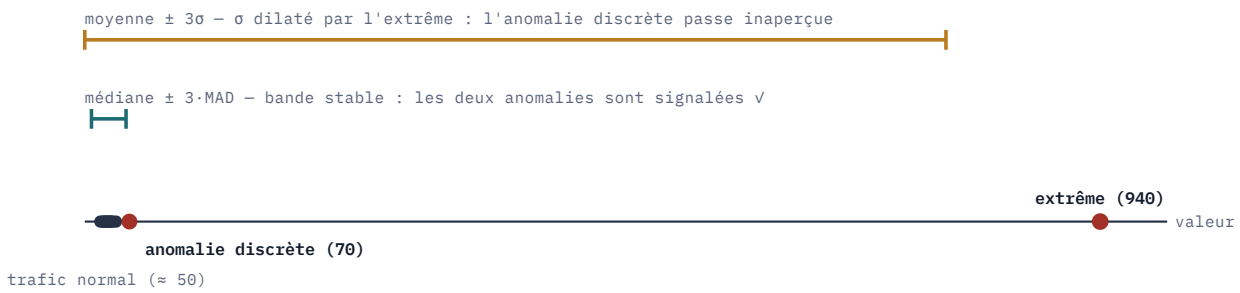


FIG. 3 Masquage. La bande « moyenne ± 3σ » (ambre) est dilatée par l'extrême et recouvre l'anomalie discrète ; la bande « médiane ± 3·MAD » (sarcelle) reste stable et les signale toutes les deux.

2.3 Les quantiles : ne rien supposer

Beaucoup de métriques de sécurité ne sont *pas* normales : tailles de requêtes, latences, octets exfiltrés suivent des lois asymétriques à longue traîne. Là, parler de « 3σ » n'a guère de sens. Les **quantiles** contournent le problème : on déclare anormal tout ce qui dépasse le 99e percentile, ou tout ce qui sort des « moustaches » `[Q1 − 1,5·IQR ; Q3 + 1,5·IQR]`, où l'IQR est l'écart interquartile. Aucune hypothèse de forme, une lecture directe en « part des observations ».

⚠ PIÈGE FRÉQUENT

Appliquer la règle des 3σ à des données fortement asymétriques produit soit un déluge d'alertes, soit un seuil absurde. Et calculer μ/σ sur un échantillon **déjà contaminé** par des anomalies auto-sabote la mesure. Réflexe : regarder la distribution avant de choisir l'échelle, et préférer médiane/MAD ou quantiles dès que la forme s'éloigne de la cloche.

À RETENIR

— $z = (x - \mu)/\sigma$ est simple mais fragile : une seule valeur extrême peut en masquer d'autres.

— Par défaut, préférez le **z-score robuste** (médiane, MAD) — stable face aux extrêmes.

— Données asymétriques ou à longue traîne ? **Quantiles / IQR** plutôt que l'hypothèse normale.

— Ne calculez jamais une échelle de dispersion sur des données déjà polluées par ce que vous cherchez.

03

PARTIE I · FONDATIONS

Du signal au score d'anomalie

Un détecteur ne dit pas « oui / non ». Il produit un *score* : une mesure continue d'étrangeté. Transformer ce score en décision — et combiner plusieurs scores — est une étape à part entière, trop souvent bâclée.

IDÉE CLÉ

Un **score d'anomalie** ordonne les observations de la plus banale à la plus étrange. Le **seuil** qui déclenche l'alerte n'est pas une propriété du détecteur : c'est une **décision opérationnelle** qui arbitre entre rappel et fausses alarmes.

3.1 Le score et la décision sont deux choses différentes

Le thermomètre indique 38,5 °C ; décider de traiter est un autre acte, qui dépend du patient et du coût de l'erreur. De même, un détecteur peut attribuer un score élevé à un événement ; **vous** décidez où placer la barre, selon le volume d'alertes que l'équipe peut absorber.

3.2 Normaliser avant de comparer, calibrer avant de croire

Deux détecteurs rendent rarement des scores comparables : l'un sort un z-score, l'autre une distance, un troisième une « probabilité » non calibrée. Pour les combiner, on les ramène à une échelle commune — rang ou **quantile** (percentile du score dans son historique), *min-max*, ou z-score du score. Un « 0,9 » ne signifie « 90 % de chances » que si le score est **calibré** ; sinon, c'est un simple rang déguisé.

EXEMPLE CHIFFRÉ

Budget d'alertes soutenable	**≈ 50 / jour**
Événements scorés / jour	**≈ 500 000**
Seuil = 99,99e percentile du score	**→ ≈ 50 alertes/j**
Règle « score > 0,8 » (fixe)	**→ 4 000 alertes/j ✗**

Fixer le seuil par **budget** (les N événements les plus étranges par jour, ou un percentile) donne une charge prévisible. Un seuil « magique » hérité d'un tutoriel ne tient aucun compte de *votre* volumétrie.

PIÈGE FRÉQUENT

Trois pièges jumeaux : (1) un **seuil fixe et magique** copié d'ailleurs ; (2) des scores **non calibrés** comparés entre détecteurs comme s'ils parlaient la même langue ; (3) un seuil réglé sur la distribution d'**entraînement**, qui ne correspond plus à la production dès que les données bougent (voir la dérive, chapitre 9).

À RETENIR

— Le détecteur produit un **score** ; le **seuil** est votre décision, pilotée par le budget d'alertes.

— Avant de combiner des scores, **normalisez** (rang, quantile) ; avant d'y croire, vérifiez la **calibration**.

— Préférez un seuil par **percentile / top-N** à un seuil fixe : la charge devient prévisible.

PARTIE II

Les grandes familles de méthodes

Quatre familles, une même question posée différemment. Pour chacune : son terrain, et ses angles morts.

4 Règles statistiques

5 Isolation Forest

6 Détection de changement

7 UEBA

II

04

PARTIE II · MÉTHODES

Règles statistiques : 3σ, EWMA, percentiles

Les détecteurs les plus simples sont aussi les plus honnêtes : des règles statistiques explicites posées sur une ligne de base. Transparentes, peu coûteuses, immédiatement explicables — c'est le cheval de trait du SOC.

IDÉE CLÉ

Une règle statistique compare une métrique à une bande attendue : seuil en σ, percentile, ou carte de contrôle. On lisse d'abord la série pour suivre la baseline, puis on alerte quand l'observation sort de la bande. Rien de caché : chaque alerte s'explique en une phrase.

4.1 Lisser pour suivre : moyennes mobiles et EWMA

Pour suivre une baseline qui bouge, on lisse. La **moyenne mobile** fait la moyenne des N dernières mesures ; la **moyenne mobile exponentielle** (**EWMA**) pondère davantage le présent : $S_t = \alpha \cdot x_t + (1 - \alpha) \cdot S_{t-1}$, avec α entre 0 et 1. Un α grand réagit vite mais tremble ; un α petit est stable mais lent. Les *cartes de contrôle* (Shewhart, EWMA) alertent quand le signal lissé franchit une bande construite autour de la baseline.

4.2 Des seuils qui respirent

Le progrès décisif n'est pas l'algorithme mais le **seuil dynamique** : une bande par heure et par jour (voir chapitre 1), de préférence robuste (médiane/MAD). Un seuil global unique est condamné à hurler aux heures de pointe et à dormir la nuit.

EXEMPLE CHIFFRÉ

Baseline EWMA (α = 0,2), S	**120 req/min**
Bande robuste ±3·MAD	**[96 ; 144]**
Observation	**181 req/min**
Hors bande (+37 au-dessus)	**alerte ✓ explicable**

L'alerte se raconte : « 181 req/min contre une base lissée de 120, au-delà de la bande des trois MAD ». Un analyste comprend, un auditeur aussi.

⚠ PIÈGE FRÉQUENT

Le danger des règles n'est pas leur simplicité, c'est leur **abandon** : un seuil réglé une fois puis jamais revu, qui se décorrèle du système. Second danger : la **prolifération**. Cent règles qui se recoupent fabriquent des tempêtes d'alertes sur un même incident. Une règle vivante se mesure, se révise, et se supprime si elle ne « paie » pas.

À RETENIR

— Les règles statistiques sont transparentes et bon marché : privilégiez-les tant qu'elles suffisent.

— Lissez la baseline (**EWMA**) et faites **respirer le seuil** (bande horaire robuste).

— Une règle non révisée est une dette : mesurez son rendement, sinon elle ne produit que du bruit.

05

PARTIE II · MÉTHODES

Isolation Forest et l'approche non supervisée

Quand les variables se multiplient et qu'aucune étiquette n'est disponible, on change de stratégie : au lieu de modéliser le normal, on *isole* l'anormal. C'est l'idée, élégante, de l'Isolation Forest.

> **IDÉE CLÉ**
> L'**Isolation Forest** découpe l'espace au hasard, encore et encore. Les points anormaux, rares et différents, se retrouvent **isolés en peu de coupes** ; les points normaux, noyés dans la masse, en demandent beaucoup. La « longueur de chemin » moyenne pour isoler un point devient son score d'anomalie [3].

5.1 Isoler plutôt que profiler

La plupart des méthodes construisent un portrait du normal puis mesurent l'écart. Liu, Ting et Zhou renversent la logique : puisque les anomalies sont « peu nombreuses et différentes », elles sont *faciles à séparer*. On construit une forêt d'arbres de partition aléatoire ; la profondeur moyenne à laquelle un point est isolé mesure sa normalité. Avantages : pas d'étiquettes, pas d'hypothèse de forme, un coût quasi linéaire, et une bonne tenue en grande dimension [3].

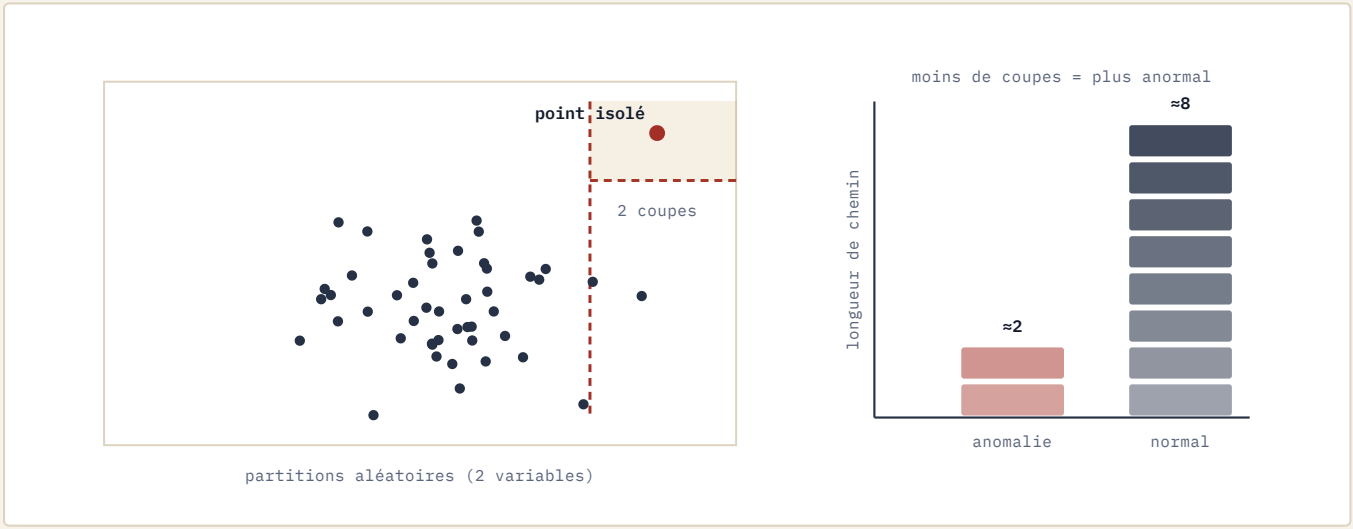


FIG. 4 À gauche, quelques coupes aléatoires suffisent à isoler le point à l'écart. À droite, la longueur de chemin : courte pour l'anomalie, longue pour un point normal. *Moins de coupes = plus anormal.*

5.2 Ce que le score dit — et ne dit pas

EXEMPLE CHIFFRÉ

Longueur de chemin moyenne — point normal	≈ 8 coupes
Longueur de chemin moyenne — anomalie	≈ 2 coupes
Score normalisé — normal	≈ 0,45
Score normalisé — anomalie	≈ 0,72
Paramètre « contamination »	0,01 (1 % supposé)

Le score croît quand la longueur de chemin chute. Mais remarquez le paramètre `contamination` : en fixant la proportion d'anomalies attendues, vous *imposez* un taux d'alertes, qu'il y ait ou non une attaque ce jour-là.

⚠ PIÈGE FRÉQUENT

Isolation Forest détecte le **rare**, pas le **malveillant**. Un nouveau serveur d'administration, une migration, un test de charge sont rares — donc bien notés, donc faux positifs. Deux autres écueils : des variables **non mises à l'échelle** ou **non pertinentes** diluent le signal ; et le modèle n'est pas explicable variable par variable sans outillage ajouté. Rare n'est pas coupable.

À RETENIR

— Non supervisé, multivarié, rapide : l'**Isolation Forest** isole l'anormal au lieu de modéliser le normal.

— Score = **longueur de chemin** courte ; mais « contamination » **impose** un taux d'alertes a priori.

— Il repère le **rare**, pas le **dangereux** : attendez-vous à des faux positifs « nouveaux mais légitimes ».

06

PARTIE II · MÉTHODES

Détection de changement : CUSUM et ruptures

Toutes les anomalies ne sont pas des points isolés. Certaines sont des *bascules de régime* : un taux qui change et *reste* changé. Les détecter vite, sans crier à chaque sursaut, demande une autre famille d'outils.

> **IDÉE CLÉ**
> La **détection de changement** cherche un déplacement durable de la moyenne ou du taux, pas un pic ponctuel. Le **CUSUM** (somme cumulée) accumule les petits écarts au niveau attendu ; tant que tout est normal, la somme reste à zéro ; dès qu'un décalage s'installe, elle grimpe et franchit un seuil de décision [4].

6.1 Point aberrant contre point de rupture

Un pic de deux minutes est un *point aberrant* ; un débit de requêtes qui double et reste doublé est un *point de rupture*. Surveiller la valeur instantanée rate les bascules lentes ; surveiller la **somme cumulée** les révèle, parce que de petits écarts répétés finissent par s'additionner.

Mécanique du CUSUM unilatéral : $S_t = \max(0,\ S_{t-1} + (x_t - \text{cible}) - k)$, où k est une marge d'insensibilité. On alerte quand $S_t > h$. Les deux boutons k et h arbitrent entre vitesse de détection et fausses alarmes.

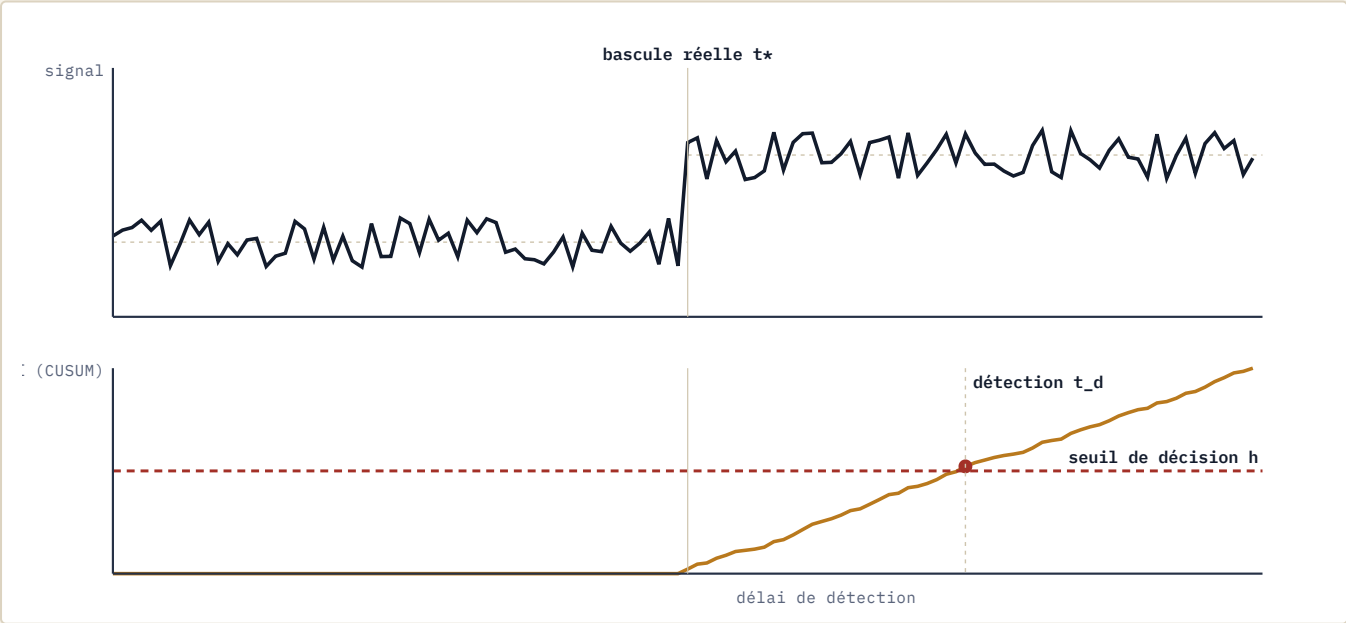


FIG. 5 En haut, le signal bascule d'un niveau ≈12 à ≈26. En bas, la somme cumulée reste plate puis grimpe et franchit le seuil h : la détection arrive un peu après la bascule — ce retard est le *délai de détection*.

6.2 Le compromis vitesse / fausses alarmes

EXEMPLE CHIFFRÉ

Niveau avant / après	**12 → 26**
Marge k	**4**
Seuil h bas	**détection rapide, + de fausses alarmes**
Seuil h haut	**détection lente, − de fausses alarmes**

Il n'y a pas de réglage gratuit : baisser h raccourcit le délai mais multiplie les fausses alertes ; le monter fait l'inverse. On choisit selon le coût relatif d'un retard et d'une fausse alarme (voir Partie IV).

⚠ PIÈGE FRÉQUENT

Le piège classique : confondre **saisonnalité** et changement. Si l'on ne retire pas d'abord le motif journalier, le CUSUM « détecte » chaque matin la montée en charge comme une rupture. Il faut **détendre et désaisonnaliser** avant d'accumuler. Et choisir le bon côté : une hausse de trafic et une chute brutale n'appellent pas la même surveillance.

À RETENIR

— Certaines menaces sont des **bascules de régime**, pas des pics : surveillez la **somme cumulée**.

— **CUSUM** détecte vite les décalages durables ; **k** et **h** arbitrent vitesse contre fausses alarmes.

— Désaisonnalisez d'abord : sinon la respiration normale du système passe pour un changement.

07

PARTIE II · MÉTHODES

UEBA : le comportement comme ligne de base

L'UEBA applique tout ce qui précède non plus à une métrique, mais au *comportement* des utilisateurs et des entités. La question devient : cet acteur s'écarte-t-il de son propre passé, ou de ses pairs ?

IDÉE CLÉ

L'**UEBA** (*User and Entity Behavior Analytics*) établit une ligne de base **par entité** — utilisateur, hôte, compte de service — et alerte sur l'écart à cette base ou à celle d'un **groupe de pairs**. Le terme vient de Gartner, qui a ajouté le « E » d'*entity* au « UBA » initial pour couvrir les acteurs non humains [6].

7.1 Soi-même et ses pairs

Deux références se combinent : l'**auto-baseline** (cet utilisateur, d'habitude, se connecte de 9 h à 18 h depuis deux postes) et la **baseline de pairs** (les autres comptables font-ils de même ?). Les variables typiques : heures et lieux de connexion, volumes lus/écrits, ressources touchées, premières apparitions (nouvel hôte, nouveau pays). Les écarts alimentent un **score de risque** agrégé dans le temps, par session ou par journée.

7.2 Un exemple d'écart comportemental

EXEMPLE CHIFFRÉ

Base de l'utilisateur	**≈ 50 lectures/j, 1 poste, 9–18 h**
Pairs (même service)	**profil comparable**
Observé	**5 000 lectures à 2 h, nouvel hôte**
Écart à soi + aux pairs	**risque élevé ✓ à investiguer**

Le signal fort n'est pas le volume seul, mais la **conjonction** : volume × heure inhabituelle × hôte jamais vu, pour quelqu'un dont les pairs ne font rien de tel. C'est la combinaison qui porte l'information.

TABLEAU 1 — LES QUATRE FAMILLES, FACE À FACE

FAMILLE	PRINCIPE	DONNÉES REQUISES	SUPERVISÉ ?	EXPLICABILITÉ	BRUIT TYPIQUE
Règles statistiques	Écart à une baseline (σ, MAD, percentiles), lissage EWMA	Une métrique, un historique propre	**Non**	**Élevée**	Seuils figés, règles non révisées, prolifération
Isolation Forest	Isoler les points rares par partitions aléatoires	Variables multiples, pas d'étiquettes	**Non**	**Moyenne***	« Rare mais légitime », contamination imposée
Détection de changement	Somme cumulée des écarts (CUSUM), ruptures	Un flux temporel désaisonnalisé	**Non**	**Élevée**	Saisonnalité prise pour un changement
UEBA	Baseline par entité + comparaison aux pairs, score de risque	Journaux riches, identités, historique long	**Hybride**	**Faible**	Baselines instables, « changement = menace », scores opaques

* Explicabilité « moyenne » : un score global est fourni nativement, mais l'attribution par variable demande un outillage supplémentaire (p. ex. explications locales).

⚠ PIÈGE FRÉQUENT

L'UEBA souffre de la **rareté des données par entité** : un compte peu actif ou récent n'a pas d'historique fiable, et sa baseline est instable — donc bruyante. Les **groupes de pairs mal définis** comparent des choux et des carottes. Surtout, le score de risque agrégé est souvent **opaque**, et repose sur une équation douteuse : « changement = menace ». Une promotion, un nouveau projet, un changement de rôle sont des changements *légitimes* qui allument l'UEBA. Sans contexte RH et métier, le dispositif génère une fatigue d'alerte considérable (voir chapitre 11).

🔖 À RETENIR

— L'UEBA, c'est la baseline du chapitre 1 appliquée au **comportement** de chaque entité et de ses pairs.

— La force vient de la **conjonction** de signaux faibles, pas d'une variable isolée.

— Données rares, pairs mal choisis, score opaque, « changement = menace » : sans **contexte**, l'UEBA fatigue.

PARTIE III

Pourquoi l'« IA » fait du bruit

La partie impopulaire, et la plus utile. Quatre mécanismes transforment un bon détecteur en générateur d'alertes.

8 Déséquilibre & taux de base

9 La dérive

10 La mauvaise métrique

11 L'absence de contexte

III

08

PARTIE III · LE BRUIT

Le déséquilibre des classes et le taux de base

Voici la raison numéro un pour laquelle les détecteurs d'anomalies noient les SOC. Elle n'est pas technologique, elle est *arithmétique* — et connue, démontrée, publiée depuis l'an 2000.

> **IDÉE CLÉ**
> Quand la classe « malveillant » est **extrêmement rare**, même un taux de faux positifs minuscule produit **beaucoup plus de fausses alertes que de vraies**. C'est le **paradoxe du taux de base** : dans la détection d'intrusion, le facteur limitant n'est pas la détection, mais le taux de fausses alarmes [1].

8.1 L'arithmétique qui tue

Prenez un million d'événements par jour et, disons, dix événements réellement malveillants noyés dedans. Un excellent détecteur attrape 90 % des attaques (il en trouve 9) avec un taux de faux positifs de seulement 1 %. Un pour cent d'un million, c'est **10 000 fausses alertes**. Sur 10 009 alertes, 9 sont vraies : la **précision** est de **0,09 %**. Pour une alerte utile, l'analyste en trie mille inutiles.

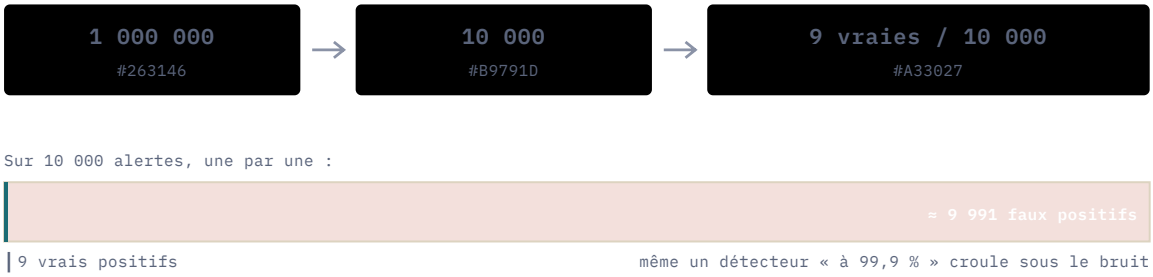


FIG. 6 L'entonnoir du taux de base. Un million d'événements, un détecteur « à 1 % de faux positifs », et il reste 9 vraies alertes noyées dans ≈10 000. Le détecteur n'est pas « mauvais » : c'est la rareté qui écrase la précision.

8.2 Ce qu'il faudrait vraiment viser

TABLEAU 2 — PRÉCISION SELON LE TAUX DE FAUX POSITIFS (10 MALVEILLANTS / MILLION, RAPPEL 90 %)

TAUX DE FAUX POSITIFS	FAUSSES ALERTES/JOUR	VRAIES ALERTES	PRÉCISION	VERDICT TERRAIN
1 %	≈ 10 000	9	**0,09 %**	inutilisable
0,1 %	≈ 1 000	9	**0,89 %**	épuisant
0,01 %	≈ 100	9	**8,3 %**	à la limite
0,001 %	≈ 10	9	**47 %**	exploitable

EXEMPLE CHIFFRÉ

Pour qu'une alerte sur deux soit vraie dans cet exemple, il faut un taux de faux positifs de 0,001 % — cent fois meilleur que le « 1 % » qui semblait déjà excellent. Voilà pourquoi la plupart des détecteurs d'anomalies, honnêtes sur le papier, sont intenables en production : ils n'ont pas été jugés à l'aune de la rareté.

⚠ PIÈGE FRÉQUENT

Le piège marketing : vanter une **exactitude** (« accuracy ») de « 99 % » ou un faible FPR, sans jamais mentionner la **prévalence**. Pire : entraîner et démontrer le modèle sur un jeu de données **équilibré** (moitié attaques, moitié trafic normal), puis le déployer dans un monde où les attaques sont une sur cent mille. La démo brille, la production hurle.

À RETENIR

— La rareté écrase la précision : un FPR « faible » suffit à produire 1000× plus de faux que de vrais.

— Le **taux de fausses alarmes** est le facteur limitant de la détection d'intrusion [1] ; jugez par la précision.

— Méfiez-vous des « 99 % d'exactitude » et des démos sur données équilibrées : demandez toujours la **prévalence**.

09

PARTIE III · LE BRUIT

La dérive : quand le normal bouge

Un modèle d'anomalie apprend une photographie du normal. Mais un système d'information n'est pas une photo : c'est un film. Quand le décor change et que le modèle reste figé, il se trompe — en silence.

> **IDÉE CLÉ**
> La **dérive** (*drift*) est l'évolution, dans le temps, de la relation entre les données et ce qu'on veut détecter. Le normal d'hier n'est plus celui d'aujourd'hui ; un seuil appris autrefois devient faux, et les fausses alertes explosent — ou, pire, des angles morts s'ouvrent. La littérature la décrit et la catégorise précisément [5].

9.1 Dérive des données, dérive du concept

On distingue la **dérive des données** (la distribution des entrées change : une migration double les volumes, un nouveau service modifie les tailles de requêtes) de la **dérive du concept** (ce qui définit « malveillant » change : l'attaquant s'adapte, se fond dans le nouveau normal). Causes fréquentes : changements d'infrastructure, saisonnalité longue, nouveaux usages, et adversaires qui apprennent de vos défenses.

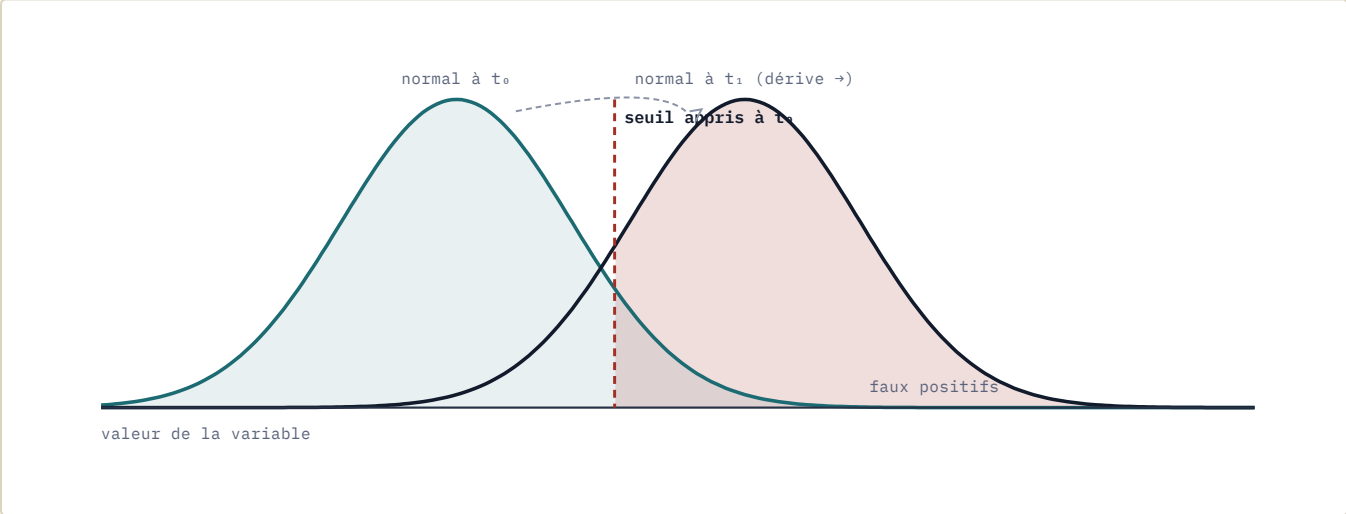


FIG. 7 Le seuil est appris sur la distribution de t_0 (sarcelle). À t_1, le trafic normal a glissé vers la droite (trait sombre) : une grande part du trafic parfaitement légitime franchit désormais l'ancien seuil. La zone rouge, ce sont des *faux positifs créés par la dérive*.

9.2 Surveiller le modèle, pas seulement le trafic

EXEMPLE CHIFFRÉ

FPR à la mise en service (t_0)	**≈ 1 %**
Après migration (t_1), seuil inchangé	**≈ 15 %**
Alertes/jour à t_0	**≈ 100**
Alertes/jour à t_1	**≈ 1 500 ✗**

Rien n'a « cassé » : le modèle fait exactement ce pour quoi il a été réglé, sur un monde qui n'existe plus. D'où la règle : surveiller en continu la **distribution des entrées** et la **performance**, et réapprendre (fenêtre glissante, modèles adaptatifs) quand la dérive est confirmée.

⚠ PIÈGE FRÉQUENT

« Entraîner une fois, déployer pour toujours » est la recette du bruit à retardement. Deux pièges miroir : ne pas **surveiller le détecteur lui-même** (qui surveille le veilleur ?), et **réapprendre sur des données dérivées mais contaminées** — on réabsorbe alors l'attaque dans le normal. Enfin, ne confondez pas une dérive avec un **incident** : un changement brutal peut être l'attaque, pas une raison de réétalonner.

À RETENIR

— Le normal **bouge** : un modèle figé dérive et fabrique des faux positifs (ou des angles morts) en silence.

— Distinguez **dérive des données** et **dérive du concept** ; surveillez entrées *et* performance [5].

— Réapprenez sur des fenêtres **propres** ; et ne prenez pas un incident pour une simple dérive à réétalonner.

10

PARTIE III · LE BRUIT

La mauvaise métrique : exactitude et ROC trompeuses

Comment un détecteur peut-il afficher « 97 % d'AUC » et pourtant inonder le SOC ? Parce qu'on l'a mesuré avec la mauvaise règle. Sous fort déséquilibre, les métriques usuelles mentent par flatterie.

> **IDÉE CLÉ**
> L'**exactitude** et la courbe **ROC** deviennent trompeuses quand une classe est très rare. La lentille honnête est la courbe **précision–rappel**, plus informative que la ROC sur données déséquilibrées [7].

10.1 Le piège de l'exactitude

Avec 10 malveillants sur un million, un détecteur qui répond toujours « normal » a une exactitude de **99,999 %**… et ne détecte rien. L'exactitude récompense la classe majoritaire ; sur des données déséquilibrées, elle est inutile.

10.2 Pourquoi la ROC flatte et la PR révèle

La ROC trace le taux de vrais positifs contre le taux de faux positifs. Or le taux de faux positifs se calcule sur l'immense population des négatifs : 10 000 faux positifs sur 999 990 négatifs, c'est un FPR de 1 %, qui « semble » excellent et dessine une belle courbe. La **précision**, elle, rapporte les vrais positifs au *total des alertes* — et s'effondre. Sur un graphe PR, la ligne du hasard n'est pas à 0,5 mais à la **prévalence** elle-même (ici 0,0015 %).

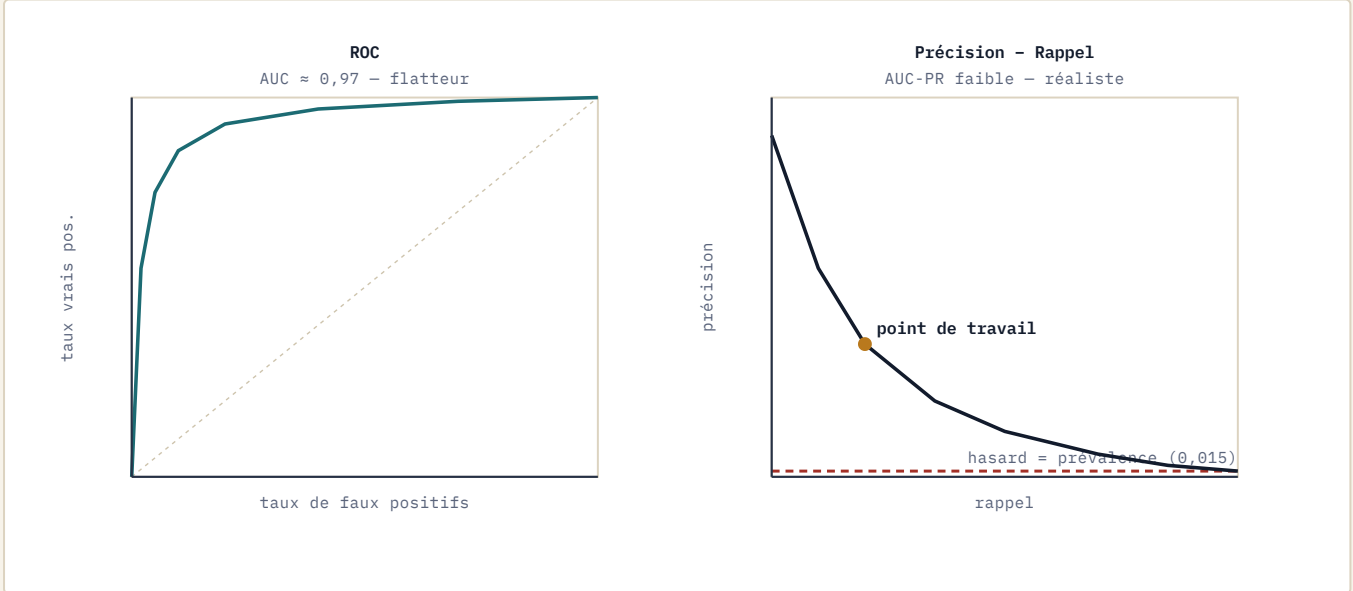


FIG. 8 Même détecteur, deux lentilles. À gauche, la ROC paraît superbe (AUC ≈ 0,97). À droite, la courbe précision–rappel révèle la réalité : la précision chute, et la barre du « hasard » est posée très bas, à la prévalence.

EXEMPLE CHIFFRÉ

Classifieur trivial « tout est normal »	**exactitude 99,999 %**
AUC-ROC du détecteur	**≈ 0,97 (flatteur)**
Précision au point de travail	**0,09 %**
AUC-PR	**faible (réaliste)**

Les deux premiers chiffres impressionnent un comité ; les deux derniers décrivent la vie de l'analyste. Exigez toujours les seconds.

⚠ PIÈGE FRÉQUENT

Optimiser ou comparer des détecteurs sur l'**exactitude** ou l'**AUC-ROC** quand les positifs sont rares : c'est se mentir. Les démos éditeurs sur jeux équilibrés tombent dans le même travers. Pour choisir un seuil, lisez la courbe **précision–rappel** et le coût des erreurs (Partie IV), pas la ROC.

À RETENIR

— Sous fort déséquilibre, **exactitude** et **ROC** flattent : elles sont portées par la masse des négatifs.

— La courbe **précision–rappel** est la mesure honnête ; sa ligne de hasard est la **prévalence** [7].

— Jugez (et choisissez le seuil) sur précision/rappel et coût — jamais sur l'« accuracy » ou l'AUC-ROC seules.

11

PARTIE III · LE BRUIT

L'absence de contexte

Un écart statistique n'est pas un verdict. « Inhabituel » ne veut pas dire « dangereux ». Sans contexte, un détecteur ne peut distinguer le rare-bénin du rare-malveillant : il produit du bruit, même parfaitement réglé.

IDÉE CLÉ

La statistique fournit la moitié du raisonnement : « c'est inhabituel ». L'autre moitié — « et c'est mauvais » — vient du **contexte** : criticité de l'actif, identité, tickets de changement, calendrier métier, renseignement sur les menaces. **Enrichir et corréler** transforme un signal en décision.

11.1 Le même écart, deux significations

TABLEAU 3 — SIGNAL IDENTIQUE, CONTEXTE OPPOSÉ

SIGNAL BRUT (Z-ROBUSTE ≈ 6)	CONTEXTE	DÉCISION RAISONNABLE
Pic de connexions sortantes depuis un hôte	Poste de test, hors production, ticket de migration ouvert	**Supprimer / basse priorité**
Pic de connexions sortantes depuis un hôte	Contrôleur de domaine, aucun changement planifié	**Alerte haute, investigation**

Même nombre, même score : tout change selon l'actif et le calendrier. Un détecteur aveugle au contexte traitera ces deux cas de façon identique, et vous apprendrez à ignorer l'un comme l'autre.

11.2 Enrichir, corréler, réinjecter

Trois leviers : (1) l'**enrichissement** — rattacher à chaque alerte la criticité de l'actif (CMDB), l'identité et son rôle, la géolocalisation, le renseignement sur les menaces ; (2) la **corrélation** — exiger une conjonction de signaux plutôt qu'un écart isolé ; (3) la **boucle de retour** — réinjecter les verdicts des analystes (vrai/faux positif) pour taire le connu-bénin et réapprendre. Un détecteur sans boucle de retour répète éternellement ses erreurs.

EXEMPLE CHIFFRÉ

Règle de suppression contextuelle : « toute anomalie de volume sur un actif portant un ticket de changement *actif* est rétrogradée en information ». Effet typique observé : une part substantielle du volume d'alertes disparaît, sans perdre de vraies détections, parce qu'on retire enfin le rare-mais-prévu.

⚠ PIÈGE FRÉQUENT

Alerter sur des anomalies **brutes**, sans enrichissement ; ignorer les **calendriers de changement** ; traiter tous les actifs **à égalité** ; et surtout, ne jamais **réinjecter** les verdicts. Chacun de ces oublis fabrique du bruit structurel qu'aucun réglage de modèle ne corrigera.

À RETENIR

— « Inhabituel » ≠ « dangereux » : la statistique dit l'écart, le **contexte** dit la gravité.

— **Enrichissez** (actif, identité, menace), **corrélez** (conjonctions), et **réinjectez** les verdicts.

— Un détecteur sans boucle de retour ni contexte métier répète ses faux positifs indéfiniment.

PARTIE IV

Juger une détection

Trois questions, une grille de dix critères. De quoi décider, preuves en main, si une détection mérite vos alertes.

12 Précision, rappel, coût

13 La grille d'évaluation

IV

12

PARTIE IV · JUGER

Précision, rappel et coût des faux positifs

Pour juger une détection pilotée par les données, trois questions suffisent presque toujours : est-elle assez *précise* à un rappel utile ? que *coûte* une erreur ? un humain comprend-il *pourquoi* elle s'est déclenchée ?

IDÉE CLÉ

Quatre cases résument tout détecteur : vrais/faux positifs, vrais/faux négatifs. La **précision** mesure la part d'alertes justes ; le **rappel**, la part d'attaques attrapées. Le bon réglage ne maximise pas une métrique symétrique : il **minimise un coût** où faux positifs et faux négatifs n'ont pas le même prix.

	RÉALITÉ : ATTAQUE	RÉALITÉ : NORMAL
ALERTE	**VP** vrai positif — détection utile	**FP** faux positif — bruit — coûte du temps
SILENCE	**FN** faux négatif — attaque manquée	**VN** vrai négatif — trafic normal ignoré

12.1 Les deux mesures qui comptent

`Précision = VP / (VP + FP)` — « quand ça sonne, est-ce vrai ? ». `Rappel = VP / (VP + FN)` — « attrape-t-on les attaques ? ». Les deux s'opposent : baisser le seuil augmente le rappel et noie la précision, et inversement. Le score F_1 est leur moyenne harmonique ; F_β permet de peser l'un plus que l'autre selon l'enjeu.

12.2 Le coût, seul vrai arbitre

EXEMPLE CHIFFRÉ

Coût de tri d'un faux positif	**≈ 10 min analyste**
Faux positifs/jour (détecteur « 1 % »)	**≈ 10 000**
→ Charge de tri	**≈ 1 667 h/jour ✗ (irréaliste)**
Coût d'un faux négatif (intrusion)	**très élevé, mais rare**
Décision	**régler le seuil sur le coût, pas sur F1**

Dix mille faux positifs à dix minutes pièce, c'est l'équivalent de plus de deux cents analystes à temps plein : impossible. Le coût rend la décision concrète : on choisit le seuil qui minimise *coût(FP)·nombre de FP + coût(FN)·nombre de FN*, pas celui qui fait joli sur une courbe.

12.3 Explicabilité : sans « pourquoi », pas de tri

Une alerte qu'on ne peut pas comprendre ne peut pas être triée. Un score de boîte noire — « risque : 0,87 » — sans preuve ni variable contributive condamne l'analyste à l'aveugle, puis à l'ignorance. Préférez

les détecteurs qui **montrent leurs raisons** : quelles variables, quel écart, quelle évidence. L'explicabilité n'est pas un luxe : c'est ce qui rend une détection *actionnable*.

⚠ PIÈGE FRÉQUENT

Optimiser F_1 « parce que c'est la métrique standard » alors que les coûts sont asymétriques ; oublier le **coût de tri** dans l'équation ; accepter une **boîte noire** non explicable. Chacun de ces choix privilégie le confort de mesure au détriment de la réalité du plateau.

🔖 À RETENIR

— Précision « quand ça sonne, est-ce vrai ? » et rappel « attrape-t-on l'attaque ? » s'opposent : arbitrez.

— Réglez le seuil pour **minimiser un coût** (FP vs FN), pas pour maximiser une métrique symétrique.

— Sans **explicabilité**, une alerte n'est pas triable : exigez le « pourquoi », pas seulement le score.

13

PARTIE IV · JUGER

La grille d'évaluation

Voici, pour finir, une grille concrète. Dix questions à poser à toute détection pilotée par les données avant de lui confier une file d'alertes. Les deux premières sont éliminatoires ; les autres sont des leviers d'amélioration.

IDÉE CLÉ

Une détection ne « vaut quelque chose » que si elle passe une **porte éliminatoire** — précision suffisante à un rappel utile, coût soutenable — puis coche assez de **critères de maturité** (mesure honnête, dérive, contexte, explicabilité, boucle de retour). Notez-la avant de la déployer.

TABLEAU 4 — GRILLE D'ÉVALUATION D'UNE DÉTECTION PILOTÉE PAR LES DONNÉES

#	QUESTION À POSER	TYPE	SI « NON »
1	La **prévalence** est-elle connue, et la **précision** estimée à un rappel cible ?	Éliminatoire	chiffre inconnu = pari
2	Le **coût** d'un faux positif et d'un faux négatif est-il explicité, et le **budget d'alertes** respecté ?	Éliminatoire	bruit garanti
3	A-t-elle été mesurée sur données **réalistes** (déséquilibrées), via précision–rappel/coût — pas exactitude ni ROC ?	Majeur	mesure flatteuse
4	Le **seuil** est-il choisi par coût / percentile, et non fixé « magiquement » ?	Majeur	charge imprévisible
5	Est-elle **explicable** (l'analyste voit pourquoi elle s'est déclenchée) ?	Majeur	non triable
6	Est-elle **robuste à la dérive** (entrées et performance surveillées, réapprentissage) ?	Majeur	décroche en silence
7	Les alertes sont-elles **enrichies et corrélées** (actif, identité, changement, menace) ?	Important	rare-bénin = bruit
8	Existe-t-il une **boucle de retour** (verdicts analystes réinjectés) ?	Important	erreurs répétées
9	La **baseline** a-t-elle été apprise sur une période **propre** ?	Important	modèle empoisonné
10	A-t-elle tourné en **rejeu** / **mode fantôme** sur données réelles avant la production ?	Important	surprise en prod

EXEMPLE CHIFFRÉ

Lecture de la grille : si une solution échoue aux questions 1 ou 2, on s'arrête — aucun réglage ne sauvera une détection dont la précision est inconnue ou le coût intenable. Au-delà, comptez les « oui » : 8–10, déployable et mûre ; 5–7, pilote sous surveillance ; moins de 5, laboratoire, pas plateau.

⚠ **PIÈGE FRÉQUENT**

Déployer sur la foi d'une **démonstration** ou d'une promesse d'éditeur, sans jamais faire tourner la détection en **rejeu** sur *vos* données ; juger l'outil sur de belles **histoires de détection** plutôt que sur sa précision mesurée. Une anecdote spectaculaire ne dit rien du bruit quotidien.

À RETENIR

— Deux portes **éliminatoires** : précision à rappel utile, et coût/budget soutenables. Le reste est amélioration.

— Comptez les « oui » : la maturité se mesure, elle ne se raconte pas.

— Toujours un **rejeu / mode fantôme** sur vos données réelles avant de confier une file d'alertes.

POUR CONCLURE

Rester maître de ses outils

La détection d'anomalies n'est ni une baguette magique ni une arnaque. C'est de la statistique appliquée, puissante quand on en connaît les limites, bruyante quand on les ignore.

Les fondations tiennent en peu de choses : le normal est une courbe qui respire ; on mesure l'écart avec des outils robustes ; un détecteur rend un score, et le seuil est une décision. Les méthodes — règles, Isolation Forest, CUSUM, UEBA — ne sont que des manières différentes de répondre à la même question, chacune avec son terrain de prédilection et ses angles morts.

Quant au bruit, il a quatre causes récurrentes, et aucune n'est mystérieuse : la **rareté** qui écrase la précision [1], la **dérive** qui périme le normal [5], la **mauvaise métrique** qui flatte au lieu d'informer [7], et l'**absence de contexte** qui confond rare et dangereux. Les reconnaître, c'est déjà la moitié du chemin pour les combattre.

Le dernier mot revient à l'analyste, pas à l'algorithme. Un outil se juge, se règle, se surveille, et se débranche s'il ne paie pas. Posez-lui les dix questions de la grille, exigez la prévalence et la précision, réclamez le « pourquoi ». Une détection qui résiste à cet examen mérite votre confiance ; les autres méritent surtout votre scepticisme. Pour une vue d'ensemble académique du domaine, la synthèse de Chandola et al. reste une excellente porte d'entrée [8].

LE GUIDE EN UNE PAGE

— Définissez le **normal** (baseline + saisonnalité) avant de parler d'anomalie.
— Mesurez l'écart avec des outils **robustes** (médiane/MAD, quantiles).
— Un **score** n'est pas une décision : le **seuil** se règle au **coût** et au budget.
— La **rareté** est l'ennemie de la précision : jugez par **précision–rappel**, jamais par l'exactitude.
— Surveillez la **dérive**, ajoutez du **contexte**, fermez la **boucle de retour**.
— Avant la prod : **rejeu** sur données réelles et passage par la **grille d'évaluation**.

§

BIBLIOGRAPHIE

Sources & références

Les affirmations importantes de ce guide s'appuient sur des travaux revus par les pairs et des publications de référence. Les renvois [n] dans le texte pointent ici.

[1] **Axelsson, S.** (2000). The base-rate fallacy and the difficulty of intrusion detection. *ACM Transactions on Information and System Security, 3(3), 186–205.*

[2] **Leys, C., Ley, C., Klein, O., Bernard, P., & Licata, L.** (2013). Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median. *Journal of Experimental Social Psychology, 49(4), 764–766.* doi:10.1016/j.jesp.2013.03.013

[3] **Liu, F. T., Ting, K. M., & Zhou, Z.-H.** (2008). Isolation Forest. *2008 Eighth IEEE International Conference on Data Mining (ICDM), 413–422.* doi:10.1109/ICDM.2008.17

[4] **Page, E. S.** (1954). Continuous inspection schemes. *Biometrika, 41(1/2), 100–115.* doi:10.1093/biomet/41.1-2.100

[5] **Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A.** (2014). A survey on concept drift adaptation. *ACM Computing Surveys, 46(4), Article 44.* doi:10.1145/2523813

[6] **Gartner (Litan, A.)** (2015). Market Guide for User and Entity Behavior Analytics. *Gartner Research — source du terme « UEBA » (ajout de l'« entité » à l'« UBA »).*

[7] **Saito, T., & Rehmsmeier, M.** (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE, 10(3), e0118432.* doi:10.1371/journal.pone.0118432

[8] **Chandola, V., Banerjee, A., & Kumar, V.** (2009). Anomaly detection: A survey. *ACM Computing Surveys, 41(3), Article 15 — lecture complémentaire.* doi:10.1145/1541880.1541882

Les chiffres des exemples sont volontairement simplifiés pour rester vérifiables de tête ; ils illustrent des ordres de grandeur, non des mesures issues d'un environnement particulier. Vérifiez toujours la prévalence et la précision sur *vos* données.